PROYECTO DE PORTFOLIO · NOVIEMBRE 2026

Lectura automática de facturas argentinas

De PDF, escaneos y fotos de celular a datos validados, con controles antifraude.

Tomás González

Ingeniería en Inteligencia Artificial · Universidad de San Andrés



Foto de celular → datos validados

✓ Lista para cargar · QR leído y verificado

Comprobante	Factura A 00004-00076009	QR + texto
Fecha	2026-03-14	QR + texto
CUIT emisor	33797543239	QR
Emisor	Distribuidora Rio Lujan S.A.S.	OCR
CUIT receptor	33574911864	QR + texto
Neto gravado	$ 828.142,66	OCR
IVA 21 %	$ 173.909,96	OCR
Total	$ 1.002.052,62	QR + texto
CAE	70497465075291	QR + texto
Vto. CAE	2026-03-24	OCR

Controles: dígito verificador de CUIT · Neto + IVA + tributos = Total · IVA 21 % del neto · Formato y vencimiento del CAE · Cada dato del QR comparado con el texto impreso

EL PROBLEMA

Cada factura que llega, alguien la carga a mano

1

Llegan en cualquier formato

PDF por mail, escaneos y fotos por WhatsApp, cada proveedor con su propio diseño.

2

Se cargan a mano

Fecha, CUIT, neto, IVA, total y CAE, una por una, al Excel o al sistema contable.

3

Los errores no se ven

Lo caro no es la factura que no se puede leer, sino la que se carga mal y nadie revisa.

Idea central del proyecto: automatizar la carga, pero **saber cuándo no confiar** en lo leído.

QUÉ HACE

Entra un comprobante, sale un dato listo o un motivo para revisar

Entrada
PDF digital
Escaneo
Foto de celular

→

Lectura y validación
OCR · QR de ARCA
reglas · controles

→

Salida
Excel y JSON
con estado y motivo

ARCHIVO	COMPROBANTE	CUIT EMISOR	TOTAL	ESTADO
factura_a_foto.jpg	A 00004-00076009	33797543239	$ 1.002.052,62	Lista para cargar
factura_a_pdf.pdf	A 00004-00076009	33797543239	$ 1.002.052,62	Revisar: Factura repetida
factura_escaneada.jpg	B 00004-00069188	33074952882	$ 1.570.352,13	Lista para cargar
trampa_total_no_cierra_foto.jpg	A 00010-00098323	30633875002	$ 1.536.692,26	Revisar: Las cuentas no cierran

Salida real del programa sobre los 4 ejemplos incluidos en el repositorio. La misma factura A está como foto y como PDF, así que la segunda copia queda como repetida.

CÓMO FUNCIONA

Cuatro pasos, y el QR como ancla

1

Leer la página

Lee el texto del PDF o, en fotos y escaneos, detecta la hoja, la endereza y aplica OCR.

2

Leer el QR de ARCA

Trae CUIT, número, fecha, total y CAE sin depender del OCR, y cada dato se compara con lo impreso.

3

Extraer el resto

Reglas que toleran los errores típicos del OCR y los distintos diseños de factura.

4

Validar y decidir

Si pasa todos los controles, se carga. Si no, va a revisión con el motivo.

Opcional: los casos dudosos se le pueden pasar a Claude, y su respuesta vuelve a pasar por los mismos controles.

CONTROLES

Qué revisa antes de aprobar un comprobante

Dígito verificador del CUIT	Errores de tipeo o de lectura en el CUIT
Neto + IVA + otros tributos = total	Totales mal calculados o montos mal leídos
IVA coherente con el neto (21 %, máximo 27 %)	IVA mal leído o mal facturado
IVA contenido en Factura B (Ley 27.743)	Dato obligatorio faltante
CAE de 14 dígitos, vigente a la fecha de emisión	Códigos de autorización inválidos
Cada dato del QR contra el texto impreso	Documentos adulterados o mal leídos
Etiqueta impresa sin monto legible	Datos que el OCR perdió sin avisar
La misma factura dos veces en el lote	Cargas duplicadas (el PDF del mail y la foto)
Antifraude · QR que apunta a un dominio que no es de ARCA	Facturas falsas o simuladas
Antifraude · Leyenda «Comprobante No Autorizado»	Borradores o comprobantes sin validez

CÓMO LO MEDÍ

Dos pruebas: una propia y una independiente

Set propio · 150 documentos

50 facturas ficticias en 3 diseños (A, B, C y notas de crédito). Cada una como PDF, escaneo y foto de celular simulada.

5 facturas «trampa» con errores a propósito: totales que no cierran, CUIT inválido, QR distinto de lo impreso.

Benchmark independiente · 200 facturas

Dataset público hecho por otra persona (Hugging Face), con 5 diseños que el sistema nunca había visto.

Ajusté las reglas mirando 55 y reporto los resultados sobre las **145 restantes**, sin mirarlas antes. También las probé como fotos de celular (esa prueba necesitó una segunda corrida; lo cuento más adelante).

RESULTADOS · SET PROPIO

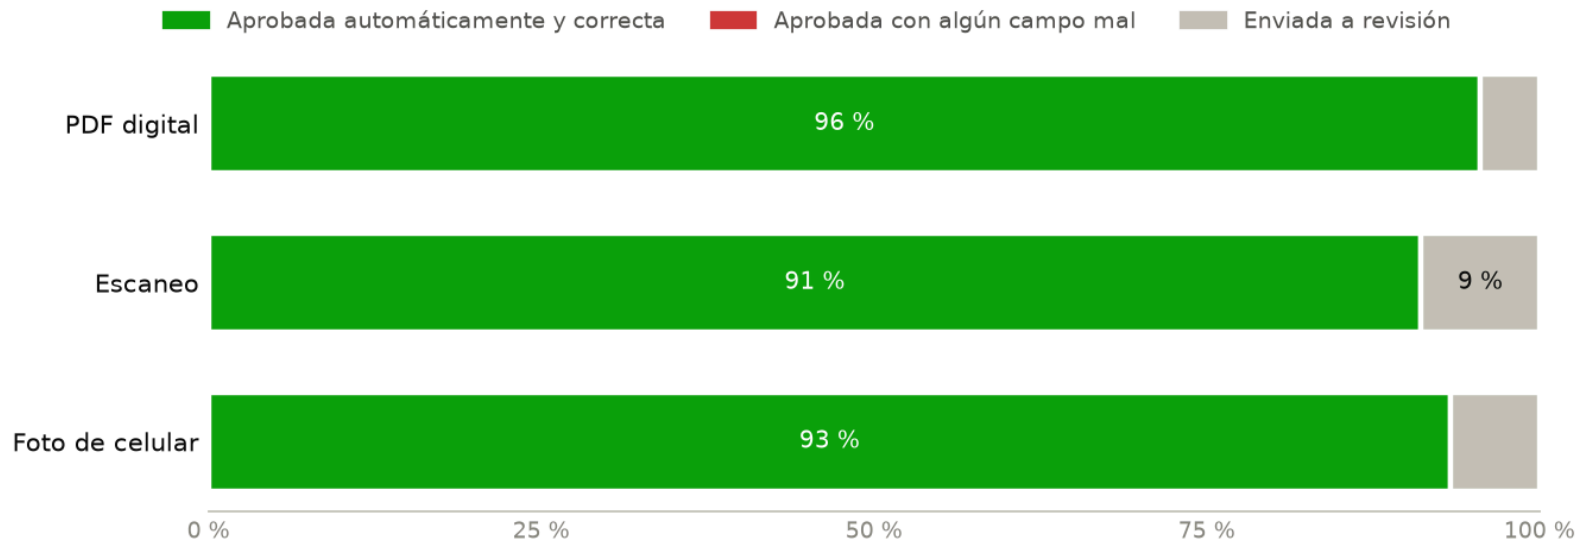
Ningún comprobante aprobado con un dato mal

0
documentos aprobados con algún dato mal

15/15
trampas detectadas (5 por formato)

95,6 %
de los PDF normales aprobados solos

93,3 %
de las fotos normales aprobadas solas



RESULTADOS · BENCHMARK INDEPENDIENTE

Diseños nunca vistos: 99,7 % de los datos correctos

99,7 %
de los campos correctos (imagen)

99,3 %
de los campos correctos (foto de celular, 2.ª corrida)

96,6 %
de las facturas con todos los datos bien

100 %
marcadas como sospechosas (ver nota)

Diseño	Imagen	Foto
baseline	29/31	28/31
cards	30/31	29/31
columns	23/24	22/24
columns_notitles	23/23	20/23
sidebar	35/36	33/36

Facturas con todos los datos correctos, por diseño

Por qué todas fueron a revisión, y está bien. Las facturas del dataset imprimen «Comprobante No Autorizado» y su QR apunta a un dominio que no es de ARCA. Una factura así no debe cargarse sola: los controles antifraude la frenaron en el 100 % de los casos.

QUÉ APRENDÍ

Lo que salió mal en el camino y cómo lo corregí

La prueba engañaba

El QR se leía en solo 24 % de las fotos. La culpa era de la simulación (fotos de 1300 px), no del lector. Ahora son de 1600 px, como en WhatsApp.

Trampas mal repartidas

Todas las facturas trampa habían caído en el mismo diseño, así que detectarlas no probaba nada. Ahora están repartidas.

Separar ajuste y prueba

Ajusté reglas con 55 facturas externas y medí sobre las otras 145. Las 5 que había abierto antes de separar pasaron a ajuste.

La foto a ciegas falló

Primera corrida: 91,6 % de campos bien. El OCR leía «($)» como «(S)». Lo corregí y volví a medir: 99,3 %, ya no a ciegas.

Un dato perdido no puede pasar

Ese error dejaba neto e IVA vacíos sin frenar la factura. Agregué un control: si la etiqueta está y el monto no, va a revisión.

Lo que el QR no cubre

Los nombres no están en el QR: un error de OCR como «Disenio» por «Diseño» no lo detecta ningún control. Es un límite conocido.

LÍMITES Y PRÓXIMOS PASOS

Qué falta para usarlo con un cliente real

- **Medir con facturas reales del cliente.** Los dos sets de prueba son sintéticos. El paso uno con cualquier empresa es probarlo sobre 50 a 100 comprobantes suyos.
- **Remitos y detalle de ítems.** Hoy lee encabezado y totales de facturas y notas. No encontré un dataset público de remitos para medirlo.
- **Nombres con tildes.** El OCR a veces lee «ó» como «6» («C6rdoba»). Una corrección de números dentro de palabras resolvería la mayoría de los errores que quedan.
- **Medir la ayuda de Claude.** Está programada y probada con tests, pero falta medirla con una clave de API.
- **Integración.** Volcar los datos aprobados a Google Sheets o al sistema contable, y la cola de revisión a una planilla compartida.

Gracias

Código, resultados y demo:
github.com/TomaasGonzalezzz/Argentine-Invoice-Extraction

Tomás González
Ingeniería en IA, UdeSA · Técnico electromecánico
linkedin.com/in/tomas-gonzalez-213a511b5

Stack: Python, OpenCV, RapidOCR, zxing-cpp, pdfplumber, pydantic.
Todas las facturas mostradas son ficticias.